

Proximal Policy Optimization (PPO)

Pietro Cestola

1 Introduzione

Proximal Policy Optimization (PPO) è un algoritmo di *reinforcement learning* appartenente alla famiglia dei policy gradient methods. Introdotto da Schulman et al. (2017), PPO combina semplicità di implementazione, stabilità numerica e buone prestazioni ed è oggi uno standard de facto in moltissimi campi.

2 Richiami di Reinforcement Learning

Immagina un'auto a guida autonoma (l'agente) che deve decidere quando frenare, accelerare o svoltare mentre percorre una strada trafficata (l'ambiente): questo è un esempio di problema in cui occorre prendere decisioni sequenziali in un ambiente incerto. Un **processo decisionale di Markov** è un modello probabilistico che descrive formalmente questo tipo di situazioni: ad ogni passo specifica come, dato lo stato corrente e l'azione scelta, vengono generate la ricompensa e il nuovo stato. La sua caratteristica distintiva è la **proprietà di Markov**: in termini probabilistici, la distribuzione del prossimo stato e della ricompensa dipende soltanto dallo stato attuale dell'ambiente e dall'azione dell'agente, e non dall'intera sequenza di eventi passati.

Definizione 1 (Processo decisionale di Markov). Un processo decisionale di Markov (MDP) è una tupla

$$M = (S, A, P, \mathcal{R}, \gamma),$$

dove:

- S è l'insieme di tutti gli **stati** dell'ambiente;
- A è l'insieme di tutte le **azioni** possibili;
- $P(s'|s, a)$ è la funzione di **transizione**, ossia la probabilità che, trovandosi nello stato s ed eseguendo l'azione a , l'ambiente transiti nello stato s' ;
- $\mathcal{R}(r|s, a)$ è la variabile aleatoria di **ricompensa**, che descrive la probabilità di ottenere la ricompensa r quando l'agente esegue l'azione a nello stato s .
- $\gamma \in [0, 1]$ è il **fattore di sconto**, che determina l'importanza relativa delle ricompense future.

Definizione 2 (Policy). Una **policy** è una distribuzione di probabilità sulle azioni condizionata dallo stato, formalmente una mappa

$$\pi : S \times A \rightarrow [0, 1], \quad (s, a) \mapsto \pi(a|s),$$

tale che, per ogni stato $s \in S$, la funzione $a \mapsto \pi(a|s)$ sia una distribuzione di probabilità sulle azioni possibili A , ossia,

$$\sum_{a \in A} \pi(a|s) = 1.$$

Definizione 3 (Dinamica). Dato $M = (S, A, P, \mathcal{R}, \gamma)$, una policy π ed uno stato iniziale s_0 estratto tramite una distribuzione ρ su S , si definisce **dinamica** la legge probabilistica che descrive l'evoluzione agente-ambiente:

- al passo t , l'agente osserva lo stato $s_t \in S$;
- seleziona un'azione $a_t \in A$ campionando da $\pi(\cdot | s_t)$;
- riceve una ricompensa $r_{t+1} \sim \mathcal{R}(\cdot | s_t, a_t)$;
- l'ambiente transita in un nuovo stato s_{t+1} secondo $P(\cdot | s_t, a_t)$.

Una **traiettoria** τ è una singola realizzazione della dinamica:

$$\tau = (s_0, a_0, r_1, s_1, a_1, r_2, \dots),$$

la probabilità di una traiettoria finita di lunghezza T è:

$$\mathbb{P}(\tau) = \rho(s_0) \prod_{t=0}^{T-1} \pi(a_t|s_t) P(s_{t+1}|s_t, a_t).$$

Definizione 4 (Ricompensa totale scontata). Dato $M = (S, A, P, \mathcal{R}, \gamma)$ e una traiettoria $\tau = (s_0, a_0, r_1, s_1, a_1, r_2, \dots)$ generata secondo la dinamica associata ad una policy π , la **ricompensa totale scontata** a partire dal passo t è definita come

$$R_t = \sum_{k=t}^{\infty} \gamma^{k-t} r_{k+1},$$

ossia la somma, scontata nel tempo, di tutte le ricompense future ricevute dopo il tempo t . Per episodi finiti di lunghezza T , la somma è intesa fino al termine dell'episodio:

$$R_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_{k+1}.$$

Definizione 5 (Funzioni valore e vantaggio). Dato $M = (S, A, P, \mathcal{R}, \gamma)$ ed una policy π si definiscono le funzioni di valore:

$$V^\pi(s) = \mathbb{E}_\pi[R_t | s_t = s], \quad Q^\pi(s, a) = \mathbb{E}_\pi[R_t | s_t = s, a_t = a],$$

e il **vantaggio**

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s).$$

Teorema 1 (Equazione di Bellman). Per ogni policy π e stato $s \in S$, la funzione valore V^π soddisfa la relazione di Bellman

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s), s' \sim P(\cdot|s,a)} [r(s, a) + \gamma V^\pi(s')].$$

In forma equivalente,

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) \sum_{s' \in S} P(s'|s, a) [\mathcal{R}(s, a, s') + \gamma V^\pi(s')].$$

Dimostrazione: vedi Appendice A.1.

3 Richiami di Policy Gradient Methods

I *policy gradient methods* sono una famiglia di algoritmi di reinforcement learning che ottimizzano direttamente la policy dell'agente per massimizzare il rendimento atteso. L'idea di base è trattare la policy come un oggetto variabile e cercare, tramite l'ottimizzazione, i parametri che la rendono più performante nell'MDP dato.

Per fare ciò, è necessario poter modificare la policy in modo continuo e calcolare come piccole variazioni dei suoi parametri influenzano il rendimento. Si introduce quindi il concetto di **policy parametrizzata**, che consente di usare metodi di ottimizzazione basati sul gradiente.

Definizione 6 (Policy parametrizzata). Sia $\Theta \subseteq \mathbb{R}^d$ uno spazio di parametri. Una policy parametrizzata è una funzione

$$\pi : S \times A \times \Theta \rightarrow [0, 1], \quad (s, a, \theta) \mapsto \pi_\theta(a|s),$$

differenziabile rispetto a θ , tale che per ogni $\theta \in \Theta$ e stato $s \in S$ la mappa $a \mapsto \pi_\theta(a|s)$ è una distribuzione di probabilità sulle azioni, ossia,

$$\sum_{a \in A} \pi_\theta(a|s) = 1.$$

In pratica, $\pi_\theta(a|s)$ è spesso implementata come una **rete neurale** che prende in ingresso lo stato e restituisce i parametri di una distribuzione sulle azioni.

Definizione 7 (Rendimento atteso). Dato $M = (S, A, P, \mathcal{R}, \gamma)$ e una policy parametrizzata π_θ , il rendimento atteso è definito come

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R_0] = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r_{t+1} \right].$$

L'obiettivo è massimizzare il ritorno atteso $J(\theta)$. I *policy gradient methods* si caratterizzano per l'uso del gradiente del rendimento atteso rispetto ai parametri della policy $\nabla_\theta J(\theta)$, detto **policy gradient**, per guidare l'aggiornamento. Un esempio concreto è l'aggiornamento tramite stochastic gradient ascent (SGA), che utilizza il gradiente per incrementare iterativamente i parametri nella direzione di massima crescita del ritorno atteso:

$$\theta_{n+1} = \theta_n + \eta \nabla_\theta J(\theta_n).$$

Per usare concretamente questi algoritmi serve avere un'espressione del gradiente della policy calcolabile numericamente. Questo richiede due fasi: prima si trova l'espressione analitica del policy gradient, che come vedremo di seguito ha la forma di un valore atteso, poi tale valore viene sostituito con una stima campionaria ottenuta dai dati raccolti in un numero finito di interazioni agente-ambiente. Lo stimatore così ottenuto $\hat{g}(\theta)$ viene infine utilizzato per aggiornare i parametri secondo lo schema scelto, ad esempio SGA:

$$\theta_{n+1} = \theta_n + \eta \hat{g}(\theta_n).$$

Questa sostituzione introduce varianza e rende necessarie strategie dedicate per controllarla e stabilizzare l'apprendimento, il **PPO** è stato progettato proprio con questo scopo.

Teorema 2 (Espressione analitica del policy gradient). L'espressione analitica del policy gradient è

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_0(\tau) \right]$$

Dimostrazione: vedi Appendice A.2.

Poiché l'espressione analitica del policy gradient è un valore atteso, possiamo stimarlo con una media campionaria. Se raccogliamo un insieme di traiettorie $\mathcal{D} = \{\tau_i\}_{i=1, \dots, N}$, dove ogni traiettoria è generata lasciando l'agente agire nell'ambiente seguendo la policy π_{θ} , otteniamo la seguente stima del gradiente:

$$\hat{g}(\theta) = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_0(\tau).$$

Prendendo un passo lungo il gradiente nella forma del Teorema 2, si incrementano le probabilità delle azioni in proporzione a $R_0(\tau)$, ossia alla somma complessiva delle ricompense osservate sulla traiettoria. Tale formulazione, però, non risulta del tutto appropriata: un agente dovrebbe rinforzare le proprie azioni esclusivamente in base alle loro conseguenze. Le ricompense accumulate prima dell'esecuzione di un'azione non forniscono informazioni utili sulla bontà di quell'azione; solo le ricompense successive ne determinano il valore. Questa intuizione è confermata dai seguenti risultati: il policy gradient può infatti essere riscritto in una forma in cui le azioni sono rinforzate unicamente in funzione delle ricompense ottenute dopo la loro esecuzione.

Teorema 3 (EGLP Lemma). Sia P_{θ} una distribuzione di probabilità parametrizzata su uno spazio Ω . Allora:

$$\mathbb{E}_{x \sim P_{\theta}} [\nabla_{\theta} \log P_{\theta}(x)] = 0.$$

Dimostrazione: vedi Appendice A.3.

Corollario 1. Il policy gradient può essere scritto nel seguente modo

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_t(\tau) \right]$$

Dimostrazione: Segue direttamente dal Teorema 3.

Tale riformulazione risulta vantaggiosa per una ragione fondamentale: nei policy gradient methods un problema critico è l'elevata varianza delle stime campionarie del gradiente, che impone di raccogliere molte traiettorie per ottenere una stima accurata. Nella formula originale erano presenti termini proporzionali a ricompense passate, aventi media nulla ma varianza non nulla, che contribuiscono soltanto a introdurre rumore nelle stime. Eliminandoli si riduce la varianza e, di conseguenza, diminuisce il numero di traiettorie necessarie per un apprendimento efficace.




Figura 1: Schema ambiente-agente con multilayer perceptron come policy parametrizzata.

4 Proximal Policy Optimization

L'aggiornamento dei parametri con il gradiente stimato può produrre variazioni troppo ampie della policy, causando instabilità e degradando rapidamente le prestazioni. Per affrontare questo problema, PPO parte dai seguenti risultati.

4.1 Risultati Preliminari

Proposizione 1. Sia $b : S \rightarrow \mathbb{R}$ una funzione dipendente dai soli stati detta *bias*. Allora

$$\mathbb{E}_{a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] = 0$$

Dimostrazione: Segue direttamente dal Teorema 3.

Nota: Questo ci permette di aggiungere o sottrarre una generica funzione bias dipendente dai soli stati dall'espressione del policy gradient, senza modificarne il valore.

Teorema 4. Sia $M = (S, A, P, \mathcal{R}, \gamma)$ un MDP, sia $\pi_\theta(a|s)$ una policy parametrizzata, e sia q una distribuzione iniziale sugli stati S . Allora il gradiente del rendimento atteso è dato da

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \nabla_\theta \log \pi_\theta(a_t | s_t) Q^{\pi_\theta}(s_t, a_t) \right],$$

Dimostrazione: vedi Appendice ??.

Corollario 2. Sia $M = (S, A, P, \mathcal{R}, \gamma)$ un MDP, sia $\pi_\theta(a|s)$ una policy parametrizzata, e sia q una distribuzione iniziale sugli stati S . Allora il gradiente del rendimento atteso è dato da

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \nabla_\theta \log \pi_\theta(a_t | s_t) A^{\pi_\theta}(s_t, a_t) \right],$$

Dimostrazione: Segue immediatamente dal Teorema 4, dalla Proposizione 1 scegliendo $b(s) = V^{\pi_\theta}(s)$ e dalla definizione di vantaggio.

4.2 Algoritmo PPO

Definizione 8 (Rapporto di probabilità). Il **rapporto di probabilità** misura come la nuova policy valuta un'azione rispetto alla policy vecchia:

$$\rho(s, a; \theta) = \frac{\pi_\theta(a|s)}{\pi_{\theta_n}(a|s)}.$$

Definizione 9 (Surrogato del policy gradient). Il **surrogato** usato per aggiornare i parametri con i dati raccolti sotto π_{θ_n} è

$$\mathcal{L}^{PG}(\theta, \theta_n) = \mathbb{E}_{\tau \sim \pi_{\theta_n}} \left[\sum_{t=0}^{\infty} \rho(s_t, a_t; \theta) A^{\pi_{\theta_n}}(s_t, a_t) \right].$$

Teorema 5. Il gradiente del surrogato calcolato nel punto θ_n corrisponde al policy gradient:

$$\nabla_{\theta} \mathcal{L}^{PG}(\theta_n, \theta_n) = \nabla_{\theta} J(\theta_n).$$

Dimostrazione: vedi Appendice A.5.

Il Teorema 5 costituisce il fondamento teorico su cui si basa il PPO: nel punto θ_n il gradiente del surrogato $\mathcal{L}^{PG}$ coincide con il gradiente del rendimento atteso $J(\theta)$. L'introduzione di $\mathcal{L}^{PG}(\theta, \theta_n)$ è funzionale all'ottimizzazione con dati finiti:

- **Riutilizzo on-policy.** Poiché l'attesa è calcolata rispetto a π_{θ_n} , gli stessi dati raccolti con π_{θ_n} forniscono stime di $\nabla_{\theta} \mathcal{L}^{PG}(\theta, \theta_n)$ per θ in un intorno di θ_n , grazie al ri-pesamento per importanza $\rho_t(\theta) = \pi_{\theta}(a_t|s_t)/\pi_{\theta_n}(a_t|s_t)$. Con la sola espressione di $\nabla_{\theta} J(\theta)$ si ottiene una direzione corretta in θ_n , ma ulteriori micro-aggiornamenti richiederebbero nuove traiettorie per restare on-policy, con costo di campionamento elevato.
- **Mini-Batch.** $\mathcal{L}^{PG}$ fornisce una funzione scalare differenziabile su cui applicare più epoche di ascesa del gradiente stocastico usando mini-batch estratti dai dati, mantenendo al primo ordine la stessa direzione di miglioramento di J nel punto θ_n , in virtù del Teorema 5.

L'efficacia di $\mathcal{L}^{PG}$ è dunque legata alla possibilità di effettuare più aggiornamenti per ogni raccolta dati, aumentando l'efficienza campionaria, pur rimanendo coerenti con il gradiente vero nel punto corrente. Il limite di questa costruzione è che, allontanandosi da θ_n , i pesi $\rho_t(\theta)$ possono crescere e amplificare varianza e instabilità. Per questo motivo, l'algoritmo utilizza una versione *clipped* del surrogato:

$$\mathcal{L}^{PPO}(\theta, \theta_n) = \mathbb{E}_{\tau \sim \pi_{\theta_n}} \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right],$$

che limita implicitamente la deviazione quando $|\rho_t(\theta) - 1|$ aumenta.

Teorema 6. Nel punto θ_n vale l'uguaglianza

$$\nabla_{\theta} \mathcal{L}^{PPO}(\theta_n, \theta_n) = \nabla_{\theta} \mathcal{L}^{PG}(\theta_n, \theta_n).$$

Dimostrazione: segue direttamente dalla definizione di clip.

Questo risultato garantisce che la funzione obiettivo troncata preservi la correttezza teorica del policy gradient nel punto attuale, ma limiti la variazione della policy quando ci si allontana troppo. L'algoritmo consiste infine nel seguente schema iterativo:

Algoritmo PPO

- 1) Si parte con una policy casuale π_{θ_n} dove $n = 0$.
- 2) Si raccoglie un insieme di traiettorie sotto π_{θ_n} e si calcola una stima di $A^{\pi_{\theta_n}}(s_t, a_t)$.
- 3) Si massimizza $\mathcal{L}^{\text{PPO}}$ usando ottimizzatori a gradiente (ad esempio Adam) per un numero limitato di epoche, suddividendo i dati in mini-batch.
- 4) Dopo alcune iterazioni di ascesa del gradiente su $\mathcal{L}^{\text{PPO}}$, si ottiene un nuovo parametro θ_{n+1} con il quale si torna al passo 2.

In sintesi: rispetto a un policy gradient on-policy “vanilla”, in cui si esegue *un solo* aggiornamento per ogni batch di traiettorie e poi si deve simulare di nuovo per restare on-policy, PPO consente di **riutilizzare lo stesso batch per più aggiornamenti** (più epoche/mini-batch). Questo è possibile grazie al surrogato con rapporto di probabilità e al *clipping*: nel punto θ_n la direzione di aggiornamento coincide con quella del gradiente vero, e quando ci si allontana il clipping controlla lo scostamento della policy. Il risultato è una **maggiore efficienza campionaria**: a parità di numero di aggiornamenti, servono meno simulazioni.

4.3 Generalized Advantage Estimation (GAE)

Una stima accurata del vantaggio $A^\pi(s, a)$ è essenziale per l'efficienza campionaria di PPO. La *Generalized Advantage Estimation* (GAE), introdotta da Schulman et al. [1], definisce una famiglia di stimatori $\{\hat{A}^{(\lambda)}\}_{\lambda \in [0,1]}$ che permette di bilanciare bias e varianza mediante un parametro di interpolazione λ .

Definizione 10 (Residuo di differenza temporale). Dato un MDP, una policy π e una funzione di valore stimata V , si definisce il residuo di differenza temporale come

$$\delta_t = r_t + \gamma m_{t+1} V(s_{t+1}) - V(s_t),$$

dove $m_{t+1} \in \{0, 1\}$ è la maschera di terminazione, pari a 0 se s_{t+1} è uno stato terminale e 1 altrimenti.

Definizione 11 (Stima GAE del vantaggio). Fissati $\gamma, \lambda \in [0, 1]$, la stima generalizzata del vantaggio al tempo t è definita come

$$\hat{A}_t^{(\lambda)} = \sum_{k=0}^{T-t-1} (\gamma\lambda)^k \delta_{t+k},$$

oppure, in forma ricorsiva per un episodio di lunghezza T :

$$\hat{A}_T^{(\lambda)} = 0, \quad \hat{A}_t^{(\lambda)} = \delta_t + \gamma\lambda m_{t+1} \hat{A}_{t+1}^{(\lambda)}, \quad t = T-1, \dots, 0.$$

Proposizione 2. Se $V = V^\pi$, allora per ogni $\lambda \in [0, 1]$ e per ogni t vale

$$\mathbb{E}[\hat{A}_t^{(\lambda)} \mid s_t, a_t] = A^\pi(s_t, a_t),$$

ossia lo stimatore GAE è non distorto.

Dimostrazione. Per l'equazione di Bellman $V^\pi(s_t) = \mathbb{E}[r_t + \gamma m_{t+1} V^\pi(s_{t+1}) \mid s_t]$ si ottiene

$$\mathbb{E}[\delta_t \mid s_t, a_t] = Q^\pi(s_t, a_t) - V^\pi(s_t) = A^\pi(s_t, a_t).$$

Per $k \geq 1$, la proprietà di Markov implica $\mathbb{E}[\delta_{t+k} \mid s_t, a_t] = 0$, da cui segue la tesi. $\square$

Corollario 3 (Casi limite). Sia $V = V^\pi$. Allora:

- per $\lambda = 0$ si ha $\hat{A}_t^{(0)} = \delta_t$ (stima a un passo, bassa varianza);
- per $\lambda = 1$ si ha $\hat{A}_t^{(1)} = R_t - V(s_t)$ (stima Monte Carlo, alta varianza).

L'algoritmo PPO impiega la stima GAE all'interno della propria funzione obiettivo per aggiornare la policy in modo stabile ed efficiente. L'idea è sostituire il vantaggio esatto $A^{\pi_{\theta_n}}(s_t, a_t)$, non direttamente calcolabile, con la stima $\hat{A}_t^{(\lambda)}$ ottenuta dal critic corrente, che fornisce un'approssimazione a varianza controllata del vero vantaggio. La funzione obiettivo con clipping utilizzata da PPO assume pertanto la forma

$$\mathcal{L}^{\text{PPO}}(\theta, \theta_n) = \mathbb{E} \left[\min \left(\rho_t(\theta) \hat{A}_t^{(\lambda)}, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t^{(\lambda)} \right) \right].$$

In questa formulazione, lo stimatore $\hat{A}_t^{(\lambda)}$ fornisce al termine di policy gradient un'informazione più stabile e meno rumorosa, consentendo di effettuare più aggiornamenti per ogni batch di dati senza degradare la coerenza on-policy. Il parametro λ regola il compromesso tra bias e varianza: valori prossimi a 1 incorporano orizzonti di previsione più lunghi e riducono il bias, mentre valori più bassi privilegiano stabilità e minore varianza. In pratica, valori di λ compresi tra 0.9 e 0.97 risultano un compromesso efficace nella maggior parte degli ambienti continui.

A Appendice

A.1 Dimostrazione dell'Equazione di Bellman

Dimostrazione. Per definizione $V^\pi(s) = \mathbb{E}_\pi[R_t \mid s_t = s]$, dove

$$R_t = r_t + \gamma R_{t+1}.$$

Applicando l'operatore di aspettazione condizionata e la proprietà di Markov otteniamo

$$V^\pi(s) = \mathbb{E}_\pi[r_t + \gamma R_{t+1} \mid s_t = s] = \mathbb{E}_{a \sim \pi(\cdot \mid s)} \left[\mathbb{E}_{s' \sim P(\cdot \mid s, a)} [r(s, a) + \gamma V^\pi(s')] \right],$$

che è l'equazione di Bellman. $\square$

A.2 Dimostrazione del Teorema 2

Dimostrazione. Sappiamo già che la probabilità di una traiettoria τ è data da

$$\mathbb{P}_\theta(\tau) = \rho(s_0) \prod_{t \geq 0} \pi_\theta(a_t \mid s_t) P(s_{t+1} \mid s_t, a_t).$$

Poiché ρ e P non dipendono da θ segue che,

$$\nabla_{\theta} \log \mathbb{P}_{\theta}(\tau) = \sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t).$$

Usando questo fatto ed il *trucco del logaritmo* ($\nabla f = f \nabla \log f$) otteniamo la tesi:

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \nabla_{\theta} \sum_{\tau} \mathbb{P}_{\theta}(\tau) R_0(\tau) \\ &= \sum_{\tau} \nabla_{\theta} \mathbb{P}_{\theta}(\tau) R_0(\tau) \\ &= \sum_{\tau} \mathbb{P}_{\theta}(\tau) \nabla_{\theta} \log \mathbb{P}_{\theta}(\tau) R_0(\tau) \\ &= \sum_{\tau} \mathbb{P}_{\theta}(\tau) \sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_0(\tau) \\ &= \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_0(\tau) \right]. \end{aligned}$$

□

A.3 Dimostrazione dell'Expected Grad-Log Prob Lemma

Dimostrazione. Denotiamo con $\mathcal{X}$ lo spazio misurabile su cui è definita la distribuzione. Osserviamo anzitutto che

$$\nabla_{\theta} \int_{\mathcal{X}} P_{\theta}(x) dx = \nabla_{\theta} 1 = 0,$$

da questo fatto e dal *trucco del logaritmo* segue la tesi

$$0 = \nabla_{\theta} \int_{\mathcal{X}} P_{\theta}(x) dx = \int_{\mathcal{X}} \nabla_{\theta} P_{\theta}(x) dx = \int_{\mathcal{X}} P_{\theta}(x) \nabla_{\theta} \log P_{\theta}(x) dx = \mathbb{E}_{x \sim P_{\theta}} [\nabla_{\theta} \log P_{\theta}(x)].$$

□

A.4 Dimostrazione del Teorema 4

Dimostrazione. Definiamo $\tau_{:t} = (s_0, a_0, \dots, s_t, a_t)$ come la traiettoria fino al tempo t e con τ_t la rimanente parte dopo di essa. Dalla legge delle aspettative iterate e dalla

proprietà di Markov segue che

$$\begin{aligned}
\nabla_{\theta} J(\theta) &= \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_t(\tau) \right] \\
&= \sum_{t=0}^{\infty} \mathbb{E}_{\tau \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_t(\tau)] \\
&= \sum_{t=0}^{\infty} \mathbb{E}_{\tau_{t:t} \sim \pi_{\theta}} [\mathbb{E}_{\tau_{t:} \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R_t(\tau) | \tau_{t:}]] \\
&= \sum_{t=0}^{\infty} \mathbb{E}_{\tau_{t:t} \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \mathbb{E}_{\tau_{t:} \sim \pi_{\theta}} [R_t(\tau) | \tau_{t:}]] \\
&= \sum_{t=0}^{\infty} \mathbb{E}_{\tau_{t:t} \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \mathbb{E}_{\tau_{t:} \sim \pi_{\theta}} [R_t(\tau) | s_t, a_t]] \\
&= \sum_{t=0}^{\infty} \mathbb{E}_{\tau_{t:t} \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) Q^{\pi_{\theta}}(s_t, a_t)],
\end{aligned}$$

che è la tesi. $\square$

A.5 Dimostrazione dell'Equivalenza del gradiente nel punto θ_n

Dimostrazione. Per definizione

$$\mathcal{L}^{PG}(\theta, \theta_n) = \mathbb{E}_{\tau \sim \pi_{\theta_n}} \left[\sum_{t=0}^{\infty} \rho(s_t, a_t; \theta) A^{\pi_{\theta_n}}(s_t, a_t) \right], \quad \rho(s_t, a_t; \theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_n}(a_t | s_t)}.$$

Derivando:

$$\nabla_{\theta} \rho(s_t, a_t; \theta) = \rho(s_t, a_t; \theta) \nabla_{\theta} \log \rho(s_t, a_t; \theta) = \rho(s_t, a_t; \theta) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t).$$

Quindi

$$\nabla_{\theta} \mathcal{L}^{PG}(\theta, \theta_n) = \mathbb{E}_{\tau \sim \pi_{\theta_n}} \left[\sum_{t=0}^{\infty} \rho(s_t, a_t; \theta) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi_{\theta_n}}(s_t, a_t) \right].$$

Valutando in $\theta = \theta_n$ si ha $\rho(s_t, a_t; \theta_n) = 1$, quindi

$$\nabla_{\theta} \mathcal{L}^{PG}(\theta_n, \theta_n) = \mathbb{E}_{\tau \sim \pi_{\theta_n}} \left[\sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta_n}(a_t | s_t) A^{\pi_{\theta_n}}(s_t, a_t) \right] = \nabla_{\theta} J(\theta_n).$$

$\square$

Riferimenti bibliografici

- [1] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation, 2018.